

ECM514 – Ciência de Dados

Projeto Desafio do 2º Semestre

Detecção e Diagnóstico de Anomalias em Sinais de Vibração

Este projeto é o desafio proposto para o segundo semestre. Como um desafio não espere não espere encontrar aqui um “exercício” com tarefas bem definidas. É um problema aberto, sem um “gabarito” de solução e que, por isso, permite que cada grupo/aluno explore diferentes técnicas/soluções. A ideia é também que o grupo/aluno investigue técnicas novas a partir do que foi aprendido, e não aplicar unicamente técnicas já apresentadas em sala.

Leiam o enunciado completo antes de formar os grupos e escolher o conjunto de dados. Aqui você encontrará o objetivo, as regras, os critérios de avaliação e os prazos das etapas do projeto.

1. Contexto

Motores rotativos (industriais, robóticos, de instrumentação científica) falham de formas características: desbalanceamento, desalinhamento, folga mecânica, defeitos de rolamento etc. Cada uma dessas falhas deixa uma "assinatura" no sinal de vibração captado por um acelerômetro. Detectar que *algo mudou* é um problema; identificar *o que* mudou é outro, mais difícil.

Este desafio pede que vocês estudem e apliquem técnicas de **detecção de anomalias** e de **diagnóstico do tipo de falha** sobre dados reais de vibração, disponibilizados publicamente pela comunidade científica.

2. Objetivo

Cada grupo deve:

1. **Escolher um dataset público, documentado**, de vibração de máquinas rotativas (lista sugerida na Seção 4; outros datasets podem ser propostos se estiverem dentro das regras do projeto – em caso de dúvida consulte o professor).
2. Investigar técnicas úteis e relevantes para o problema, e **propor pelo menos uma solução de detecção de anomalias e diagnóstico do tipo de falha**.
3. Implementar, avaliar o desempenho de diferentes alternativas e/ou do *ground truth*.
4. Discutir criticamente os resultados: o que funcionou, o que não funcionou, e por quê.

3. Regras do desafio

- **Grupo e tema.** Grupo de no máximo 6 alunos. Faça o cadastro do dataset de escolha até 17.09.2026.
- **O dataset empregado deve ser público e documentado** (descrição do experimento, taxa de amostragem, tipos de falha, condições de operação). Datasets sem documentação mínima não é aceito, mesmo que os dados estejam disponíveis.
- **Não é permitido usar dados sintéticos** gerados artificialmente para este desafio. O objetivo é lidar com dados reais, embora algumas fontes aqui tenham gerado dados simulados.
- **O código da implementação deve ser 100% executável e reproduzível.**

4. Datasets sugeridos

Todos são públicos e amplamente citados na literatura de manutenção preditiva, e cobrem diferentes tipos de problemas e defeitos em rolamentos e motores:

Dataset	O que contém	Link
CWRU (Case Western Reserve University)	Rolamento: pista interna, pista externa, esfera, vários diâmetros de defeito	engineering.case.edu/bearingdatacenter https://www.kaggle.com/datasets/astrollama/cwru-case-western-reserve-university-dataset
Paderborn University (KAT-DataCenter)	10 classes de defeito de rolamento, incluindo dano real por fadiga acelerada (não só artificial)	kaggle.com/datasets/dippatel03/paderborn-db
University of Ottawa (UOEMD-VAFCVS)	Desbalanceamento, desalinhamento, defeitos de estator/rotor, rolamento	ncbi.nlm.nih.gov/pmc/articles/PMC11636780 https://www.kaggle.com/datasets/guilhermeparcerao/university-of-ottawa-electric-motor-dataset
IMS / NASA Bearing Dataset	Degradação até a falha (run-to-failure); útil também para quem quiser explorar previsão de vida útil remanescente	kaggle.com/datasets/vinayak123tyagi/bearing-dataset
MFPT (Machinery Failure Prevention Technology)	Rolamento: pista interna/externa	kaggle.com/datasets/emperorpein/mfpt-fault-datasets

Grupos podem propor outro dataset público além desta lista, desde que documentado e aprovado previamente pelo professor.

5. Técnicas: o que pode ser explorado

Não há uma técnica obrigatória, nem uma lista fechada de opções. A escolha e a justificativa da técnica fazem parte do desafio. Cabe a cada grupo pesquisar a literatura de manutenção preditiva e de detecção de anomalias, e propor a abordagem que considerar mais adequada ao dataset escolhido, com a devida fundamentação bibliográfica.

Grupos são livres para combinar mais de uma técnica (ex.: uma para detectar, outra para diagnosticar o tipo de falha).

6. Entregáveis

Em um GitHub do projeto (recomenda-se empregar uma organização no GitHub), havendo com:

1. Um **notebook**, 100% executável no Colab, com as análises desenvolvidas. Instruções no readme para reprodutibilidade.
2. Os dados empregados (se > que o limite do GitHub, empregar um drive público)
3. Um **Relatório Técnico** (texto do trabalho) com os principais aspectos da análise (pode estar no corpo do notebook se preferirem, ou em um texto à parte .docx, markdown ou Latex).
 - **Descrição do dataset:** origem, setup físico do experimento, taxa de amostragem, tipos de falha rotulados, quantidade de amostras por classe.
 - **Fundamentação:** por que a(s) técnica(s) escolhida(s) fazem sentido para esse problema, com pelo menos 2 referências bibliográficas por técnica.
 - **Metodologia:** como os dados foram divididos (treino/teste), como as features foram extraídas, como o modelo foi treinado/ajustado.
 - **Resultados**, no formato padronizado abaixo.
 - **Discussão crítica:** limitações da técnica, casos em que falhou, o que mudaria com mais tempo/dados.
 - **Referências e declare usos de IA**
4. **Link para uma apresentação de no máximo 5min no YouTube** e respectivos slides empregados
5. **Sumário no readme**, apontando para cada uma das entregas

6.2 Tabela Resumo de Resultados

Incorporar ao texto e readme uma tabela resumo dos resultados como abaixo (exemplo ilustrativo)

Dataset	Técnica	Tipo de falha identificada	Taxa de detecção (TPR)	Falso positivo (FPR)	Acurácia por classe (se houver diagnóstico)

- Se a técnica só detecta anomalia (não diagnostica o tipo): preencher TPR/FPR e deixar "Tipo de falha identificada" em branco ou como "não se aplica".
- Se a técnica também classifica o tipo de falha: preencher "Tipo de falha identificada" com a(s) classe(s) do dataset que o modelo reconheceu, e incluir **matriz de confusão** completa (todas as classes do dataset) como anexo.

7. Rubrica/Critérios de avaliação

Critério	Peso
Levantamento e Seleção dos métodos	1
Aplicação dos métodos e métricas	2
Resultados Detecção	2
Resultados Classificação	1
Qualidade da discussão crítica (o que funcionou, não funcionou e por que)	2
Apresentação Relatório, Repositório e Código	1
Apresentação	1

8. Algumas Referências de partida (Fundamentação teórica)

- RANDALL, R. B. *Vibration-based Condition Monitoring*. Wiley, 2011. onlinelibrary.wiley.com/doi/book/10.1002/9780470977668
- RANDALL, R. B.; ANTONI, J. Rolling element bearing diagnostics: a tutorial. *Mechanical Systems and Signal Processing*, v. 25, n. 2, p. 485-520, 2011. doi.org/10.1016/j.ymssp.2010.07.017
- ISO 20816-1:2016. Mechanical vibration: measurement and evaluation of machine vibration. iso.org/standard/63180.html
- SMITH, W. A.; RANDALL, R. B. Rolling element bearing diagnostics using the Case Western Reserve University data: a benchmark study. *Mechanical Systems and Signal Processing*, v. 64-65, p. 100-131, 2015. (leitura recomendada antes de usar o CWRU: discute limitações conhecidas do dataset) sciencedirect.com/science/article/abs/pii/S0888327015002034